

# 用于假手机电控制的递归神经网络模型

特奥多-阿德里安·特班  
自动化与应用信息系蒂米什瓦拉  
理工大学罗马尼亚蒂米什瓦拉  
adrian.teban@student.upt.ro

阿德里亚娜阿尔布  
自动化与应用信息系蒂米什瓦拉  
理工大学罗马尼亚蒂米什瓦拉  
adriana.albu@aut.upt.ro

Radu-Emil 预杯  
自动化与应用信息系蒂米什瓦拉  
理工大学罗马尼亚蒂米什瓦拉  
radu.precup@aut.upt.ro

Claudia-Adina Bojan-Dragos  
自动化与应用信息系。蒂米什瓦  
拉理工大学  
罗马尼亚蒂米什瓦拉  
claudia.dragos@aut.upt.ro

埃琳娜-克里斯蒂娜·伦卡  
自动化与应用信息系蒂米什瓦拉  
理工大学罗马尼亚蒂米什瓦拉  
luncaelenacristina@yahoo.com

Emil M. Petriu  
School of EECE  
University of  
Ottawa 加拿大渥  
太华  
petriu@uottawa.ca

**摘要**——本文提出了一组循环神经网络 (RNN)，能够复制基于表面肌电传感器的假手的非线性机制。RNN 的实验结果表明系统在训练数据上的结果很好，在验证数据上的结果也可以接受。包括了开发的 RNN 与类似大小的非递归神经网络之间的比较。

**关键词**——手指角度、屈曲百分比、肌电传感器、假手、循环神经网络

## I. 介绍

下臂假肢系统的创建围绕着来自肌肉的肌电信号 (MES) [1]–[3] 的模式识别。重要的任务是将手臂的运动与肌肉激活相关联，以模拟非线性动态系统。神经网络 (NN) [4]、[5]、插入 NN [6] 中的最大 Lyapunov 指数和演化模糊模型 [7] 通常用于对该非线性系统建模。[8]–[10] 中描述了基于 MES 的假臂和手控制的实际成就。[11]–[13] 中介绍了模糊控制和建模的最新结果。通过使用电脉冲刺激神经通路对手臂进行功能性电刺激是另一种在神经损伤的情况下恢复运动而无需截肢的方法。

本文提出了一种用于假手机电控制系统的系统架构和人手动力学的可变结构 RNN 模型，即在基于肌电的控制系统中用作参考模型的手指动力学。这个非线性系统的输入是从放置在人体手臂上的八个传感器获得的 MES，输出是对应于中腕关节角度的屈曲百分比。为了简单起见，在本文的其余部分中，弯曲百分比也称为弯曲百分比和手指角度。

系统架构基于 [13] 中给出的通用架构和 [14] 中报告的结果，但本文的重点是比例-积分-微分 (PID) 控制器，它们旨在首先用于实际应用-假肢系统的时间控制。手指动力学涉及的角度实际上是中腕关节角度，以下简称为手指角度。

所提出的可变结构递归神经网络 (RNN) 被用来代替非递归神经网络，因为它能够从之前的步骤 ( $tn-1$ ,  $tn-2$ , ...) 中学习，这意味着这个特定的非线性动态系统具有更好的性能。本文考虑的 RNN 是长短期记忆 (LSTM) [15]、[16]，它将与常规神经网络 (NN) 进行比较，以评估这种方法的优缺点。

该论文证明了 RNN 能够复制真实人手的非线性机制。该输出用于通过本文中介绍的系统架构来驱动假手。部分考虑了手指屈曲的动力学，暂时忽略假手延迟。这出现在拟议的申请中，因为手指弯曲被用作假手的参考。

关于实验设置的细节（例如，使用了什么传感器，什么灵敏度，频带，电极等）在续集中没有给出，因为本文主要集中在建模上。但是，与传感器放置相关的最低技术细节将在下一节中介绍。没有给出在假手控制中使用所得结果的具体细节，因此忽略了手指弯曲的动力学。

该论文提出了一个循环神经网络来模拟八块受伤肌肉的激活与五个手指的弯曲之间的关系。该模型的目的是为假手的手指生成弯曲参考，由 PID 控制器控制。除了 10 和 100 个样本期间的平均输入之外，提议的 RNN 使用 100 个过去的输入值。得到的结果是

与使用与 RNN 相同的输入、平均输入和一层神经元的常规 NN 获得的结果相比。还将结果与使用验证数据进行训练获得的结果进行比较。

本文组织如下：传感器设置将在下一节中介绍，涵盖传感器的类型、数量和位置。整个系统架构在第 III 节中讨论，涉及不同模块之间的通信。RNN 架构在第 IV 节中进行了描述，将主题视为结构、参数数量和神经元类型。第五节包含结果和与其他神经网络模型比较，第六节总结了结论和未来的改进。

### II. 传感器及其放置

肌电传感器本质上是差分放大器，将从肌肉接收到的电信号转换为微控制器可以读取的信号，如图 1 所示。信号被放大 200 倍，然后从最大值 (-5V; +5V) 整流至 (0V; 5V)。最后一步是将信号从快速变化平滑到平均值，以减少微控制器上的负载。这种类型的传感器用于许多版本的下臂假肢 [17]–[19]，因为它们相对易于使用并且不需要手术来放置它们。



图 1. 肌电传感器。

传感器直接放置在肌肉上方或尽可能靠近，以便读取来自目标肌肉的信号，并最大限度地减少来自其他肌肉的干扰。8 个传感器的放置如下：如图 2 所示，在指浅屈肌上有 4 个传感器，如图 2 中，在指伸肌上有 2 个传感器，在小指伸肌上有 1 个传感器，在拇长展肌上有 1 个传感器，如图 2 所示。在图 3 中。



图 2. 传感器 1 到 7 在手上的位置。



图 3. 传感器 8 在手上的位置。

### III. 系统架构

该系统由三大模块组成：采集模块、神经网络模块和执行器模块，如图4所示。

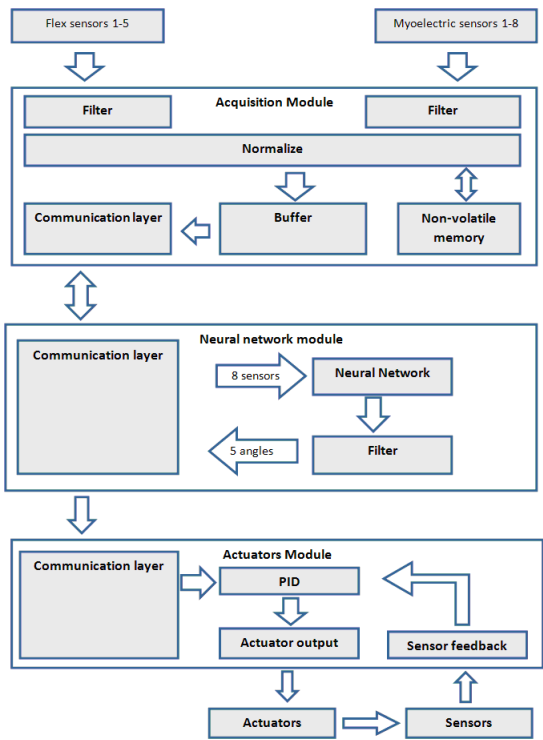


图 4. 假手控制系统架构。

系统的拆分是为了将神经网络的复杂性降低到一个简单的多输入多输出（MIMO）系统，专门用于将 MES 的非线性输入映射到手指的弯曲角度。在这种情况下，可以轻松计算 NN 性能，而不受外部因素的影响。

采集模块基于Atmega8微控制器，负责MES信号和柔性传感器信号的实时采集。采集周期为 10 毫秒，值通过第一层过滤，去除不需要的噪声。过滤后的值然后进入标准化阶段，为每个传感器设置相同的范围（柔性传感器为 0% 到 100%，肌电传感器为 0 到 255）。每个手指的弯曲传感器的传感器范围从 0% 到 100% 代表手指完全打开和完全闭合。对于 MES，0 到 255 的范围只是 8 位的最大值，代表目标肌肉可以接收的电脉冲。选择 8 位是为了避免由电缆引起的不必要的噪声，同时也减轻了神经网络的负载。然后将获得的值通过串行接口发送到神经网络模块进行处理。

采集模块以两种模式工作：训练模式和正常模式。在训练模式下，它会发送柔性传感器测量值和 MES 测量值，因为系统是在健康的手上使用并创建相关性

然后用于训练神经网络的传感器之间。在正常模式下，柔性传感器断开连接并且没有值发送到 NN。

进入正常模式的神经网络模块将 8 个传感器作为输入，并输出与中腕关节角度对应的每个手指的屈曲百分比。

然后再次过滤此输出以消除噪声并使其平滑，然后将其发送到执行器。NN 的训练在高性能设备上单独进行，并将测量的 MES 和屈曲百分比作为输入。

执行器模块负责将 RNN 发送的手指闭合百分比转换为假肢手指运动。这种运动的控制是通过适当设计的 PID 控制器实现的，该控制器控制执行器（伺服系统）并有两个输入：来自 RNN 的屈曲百分比和来自假手的传感器反馈（力、角度）。

#### IV. 递归神经网络架构

LSTM 将  $t_n$  值和过去的  $x$  值作为输入，在本例中  $x = 100$  (1 秒)，采样周期为 10 毫秒。所选择的 1 s 循环是手指快速和平均收缩速度的覆盖值，它更依赖于过去的值。慢速运动（超过 1 秒）更依赖传感器平均值，如续集所示。

网络的内部结构（仅针对一个时间戳）使用了图 5 所示的四层：输入层、LSTM 层、隐藏层和输出层




图 5. LSTM 网络层。

对于每个时间戳  $n$ ，输入层由 24 8 3 个神经元组成，这些神经元取输入向量

$$[Z^T \quad A^T \quad S^T]^T \quad (1)$$

由八个元素的三个串联向量组成 ( $T$  表示矩阵转置)：

$$\mathbf{Z} = [z_{1,n} \quad z_{2,n} \quad z_{3,n} \quad z_{4,n} \quad z_{5,n} \quad z_{6,n} \quad z_{7,n} \quad z_{8,n}]^T, \quad (2)$$

其中  $z_{j,n}$  是肌电传感器  $j$  的输出， $j=1\cdots 8$ ,

$$\mathbf{A} = [a_{1,n} \quad a_{2,n} \quad a_{3,n} \quad a_{4,n} \quad a_{5,n} \quad a_{6,n} \quad a_{7,n} \quad a_{8,n}]^T, \quad (3)$$

和

$$a_{j,n} = (\sum_{i=0}^9 z_{j,n-i}) / 10 \quad (4)$$

作为肌电传感器  $j$  的过去十个样本 (100 ms) 的平均值， $j=1\cdots 8$ ，和

$$\mathbf{S} = [s_{1,n} \quad s_{2,n} \quad s_{3,n} \quad s_{4,n} \quad s_{5,n} \quad s_{6,n} \quad s_{7,n} \quad s_{8,n}]^T, \quad (5)$$

在哪里

$$s_{j,n} = (\sum_{i=0}^{99} z_{j,n-i}) / 100 \quad (6)$$

是肌电传感器  $j$  过去 100 个样本 (1 s) 的平均值， $j=1\cdots 8$ 。

$Z$ 、 $A$  和  $S$  向量是根据实验配置选择的，以获得最佳精度，即传感器瞬时值之间的组合。100 毫秒和 1 秒的平均值表现出最好的结果。

LSTM 层包含从输入层连接的神经元以及与前几层的连接。它被配置为 300 个神经元的 LSTM 层，并且与过去的 100 个时间步长有联系。LSTM 层和隐藏层的大小从 50 (大约  $\sqrt{\text{inputlayer} \times \text{timesteps}}$ ) 到 300 通过参数调整提高 7% 的准确性，而不增加不切实际的参数数量和训练时间。

隐藏层仅连接到当前的 LSTM 层，并且还包含 300 个神经元，用于对非线性行为的输入进行新的抽象。此层还使 LSTM 能够在第一秒内输出值，而无需等待接收到前 100 个样本。这在 NN 模块故障和重启的情况下很有用，其中系统停机时间缩短为 1 秒。

两种类型的 RNN 操作在图 6 中描述了前 1 秒 (MIMO 系统结构) 和图 7 中的正常功能 (多输入 - 单输出系统结构)。因此，图6和图7的整体描述对应于一个变结构的RNN。




图 6. 第一秒的 LSTM 网络。




图 7. 第一秒后的 LSTM 网络。

最后一层是包含五个神经元的输出，输出向量  $O$ :

$$O = [o_{1,n} \ o_{2,n} \ o_{3,n} \ o_{4,n} \ o_{5,n}]_T \quad (7)$$

收集每个手指在时间戳  $n$  的屈曲百分比。

使用公式 [15] 计算 LSTM 网络参数  $n_p$

$$n_p = 4[S0(SI - 1) + SO^2] \quad (8)$$

其中  $SI$  是输入层大小,  $SO$  是输出层大小。右边项前面的 4 来自循环层, 对于每个神经元, 循环层包含三个门(读/写/忘记)和细胞状态的第四个参数。

该模型总共包含 1,112,705 个经过训练的参数。它们的分布如下: 第一个 LSTM 层中有 390,000 个, 隐藏 LSTM 层中有 721,200 个, 输出层中有 1,505 个。

#### V. 循环神经网络结果

将 RNN 模型结果与真实手部动作(由柔性传感器捕获)进行比较, 使用均方根误差(RMSE)提出的性能标准进行比较, 以表达模型精度:

$$\text{均方根误差} = \sqrt{\frac{1}{D} \sum_{n=1}^D (o_{l,n} - y_{l,n})^2} \cdot 100, \quad (9)$$

其中  $l = 1 \dots 5$  表示目标手指,  $D$  是数据集中数据样本的数量, 验证数据集的  $D = 18,490$ ,  $y_{l,n}$  是手指的弯曲百分比  $l = 1 \dots 5$  在真实手中。训练和验证数据集对获得的结果有重大影响。

网络训练是在 110,374 个样本的训练数据集上完成的, 相当于 1,103.74 秒。每个时间样本由 24 个输入组成, 如 (1) 至 (6) 所示, 以及对每个手指屈曲百分比的五个输出。

根据训练性能, RNN 在验证数据上的 RMSE 值为 8% 到 9%, 并与具有 2 层 300 个神经元的常规 NN 进行比较(图 8), RMSE 为 13% 到 14%。对于性能基准, RNN 的另一个实例

为了模拟更完整的数据集, 还创建了经过验证数据训练的数据集, 达到了 2% 的 RMSE。

每个手指的示例如下所示: 拇指 ( $l = 1$ , 图 9), 输出 ( $l = 2$ , 图 10), 中指 ( $l = 3$ , 图 11), 无名指 ( $l = 4$ , 图 12) 和小指 ( $l = 5$ , 图 13)。每个图都概述了预期结果(蓝色)、常规 NN(红色)、RNN(绿色)和当测试数据也用于训练 RNN(洋红色)时的 RNN 之间的比较。所有数字都说明了仅 1 到 2 s 数据的结果 184.9 s 以适合纸张。



图 8. 具有相似大小的常规神经网络 (2 层, 每层 300 个神经元)。

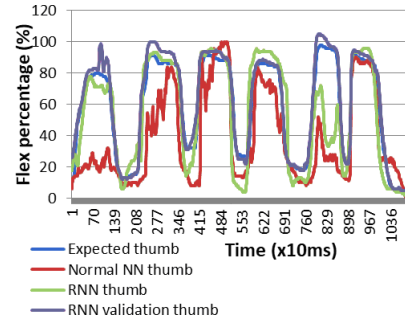


图 9. 预期结果(蓝色)、常规 NN(红色)、RNN(绿色)和使用验证数据训练的 RNN(洋红色)的拇指结果。




图 10. 预期结果(蓝色)、常规 NN(红色)、RNN(绿色)和使用验证数据训练的 RNN(洋红色)的食指结果。




图 11. 预期结果(蓝色)、常规 NN(红色)、RNN(绿色)和使用验证数据训练的 RNN(洋红色)的中指结果。

一般来说，对于每个手指，RNN 都优于常规 NN，但是，如图 9 所示。但是，在某些情况下，两个网络都会遇到未经训练的情况（第五次移动），并且不会按预期复制手指移动。通过使用验证数据（图 9 中的洋红色线）训练 RNN 覆盖案例后，表明新的 RNN 给出了更准确的结果。在一个手指的输出受另一块肌肉影响的情况下，结果也会有所改善（图 14）。在这里，小指（黑色）的弯曲会影响 booth he RNN（绿色）和正常 NN（红色）的索引输出，因为该场景缺乏训练数据。




图 12. 预期结果（蓝色）、常规 NN（红色）、RNN（绿色）和使用验证数据训练的 RNN（洋红色）的无名指结果。




图 13. 预期结果（蓝色）、常规 NN（红色）、RNN（绿色）和使用验证数据训练的 RNN（洋红色）的小指结果。




图 14. 受小指影响的食指。

训练结束后，RNN 不再受到影响，输出（洋红色）遵循食指（蓝色）的期望输出。尽管如此，本节中给出的结果证明，在常规网络上使用循环神经网络的必要性是合理的。

## VI. 结论

本文提出了新的可变结构 RNN，用于对 MES 的非线性动态输出进行建模。获得的模型用于假手控制。就 9% 到 14% 的平均绝对误差而言，RNN 获得的结果优于非循环单层 NN [4]，而此处考虑的常规 NN 具有相似的大小，因为循环层增加了输入的时间演化。

训练数据和测试数据输出之间的比较显示了对训练数据的过度拟合。这将通过添加更多训练样本（当前训练数据包含一个时间窗口，记录宽度约为 1103 秒）以及更多传感器稍微偏离理想位置的样本来补偿。

由于通过添加更多的神经元和层来增加 RNN 的大小会在性能上提供小的改进，因此未来的研究将集中在预处理 RNN 输入以及通过添加更多特征来处理神经网络。来自其他线性和非线性系统模型和应用的有用结果将被嵌入，包括大规模复杂系统 [20]、进化和自学习系统 [21]、[22]、汽车和航空系统 [23]–[25]，移动机器人 [26]–[29]、模糊建模和控制 [30]–[34]、其他 NN 架构 [35]–[39]、神经元相位恒常性和使用分数阶模型开发阶梯网络模型 [40]–[42]。

执行器模块在算法设计、硬件和软件实现方面的发展也是未来研究的一个方向。图 4 突出显示了在初始模拟和下一个实验中使用的一种控制器类型。

## 致谢

这项工作得到了埃森哲和加拿大 NSERC 的支持。

## 参考文献

- [1] J. G. Hincapie 和 R. F. Kirsch, “基于 EMG 的神经网络控制器用于上肢神经假体的可行性”, IEEE Trans. 神经系统. 康复. 英语, 卷. 17, 没有. 1, 第 80–90 页, 2009 年 2 月。
- [2] R. N. Khushaba, A. Al-Ani 和 A. Al-Jumaily, “多功能肌电手控制的正交模糊邻域判别分析”, IEEE Trans. 生物医学. 英语, 卷. 57, 没有. 6, 第 1410–1419 页, 2010 年 6 月。
- [3] A. Balbinot, A. S. Júnior 和 G. W. Favieiro, “通过肌电信号和人工神经网络解码手臂运动”, Intell. 控制自动化, 卷. 4, 没有. 1, 第 87–93 页, 2013 年 2 月。
- [4] R. J. Smith, F. Tenore, D. Huberdeau, R. Etienne-Cummings 和 N. V. Thakor, “从表面 EMG 信号连续解码手指位置以控制动力假肢”, Proc. 30号

- 安. 诠释. 会议. IEEE 工程师. 医学. 生物学. Soc., 加拿大不列颠哥伦比亚省温哥华, 2008 年, 第 197-200 页。
- [5] T.-A. Teban, R.-E. Precup, T. E. A. de Oliveira 和 E. M. Petriu, “用于基于肌电的假手控制的递归动态神经网络模型”, Proc. 2016 年 IEEE 国际. 系统. 会议, 美国佛罗里达州奥兰多市, 2016 年, 第 1-6 页。
- [6] Y. Guo, G. R. Naik, S. Huang, A. Abraham 和 H. T. Nguyen, “用于准确肌电信号分类的非线性多尺度最大李雅普诺夫指数”, Appl. 软计算, 卷. 36, 第 633-640 页, 2015 年 11 月。
- [7] 关于. Precup, T.-A. Teban, T. E. A. de Oliveira 和 E. M. Petriu, “基于肌电的假手控制的进化模糊模型”, Proc. 2016 年 IEEE 国际. 会议. Fuzzy Syst., 加拿大不列颠哥伦比亚省温哥华, 2016 年, 第 72-77 页。
- [8] DARPA, “Proto 2”, 大众科学. 杂志, 2007 年 8 月。
- [9] Advanced Arm Dynamics, “费城, 欢迎来到仿生时代”, 地铁, 2011 年 7 月。
- [10] Advanced Arm Dynamics, “Advanced surgery helps 13-year-old move prosthetic arm”, 哥伦比亚广播公司明尼苏达州, 2015 年 9 月。
- [11] M. Tabakov, K. Fonal, R. A. Abd-Alhameed 和 R. Qahwaji, “基于肌电信号分析的实时模糊仿生手控制”, 载于计算集体智能. ICCCI 2016, N. T. Nguyen, L. Iliadis, Y. Manolopoulos 和 B. Trawinski, Eds. Cham: Springer, 计算机科学讲义, 卷. 9875, 第 292-302 页, 2016 年。
- [12] M. Tabakov, K. Fonal, R. A. Abd-Alhameed 和 R. Qahwaji, “基于肌电信号分析的实时仿生手控制”, 《计算集体智能交易》XXIX, N. T. Nguyen 和 R. Kowalczyk, 编辑. Cham: Springer, 计算机科学讲义, 卷. 10840, 第 21-38 页, 2018 年。
- [13] 关于. Precup, T.-A. Teban, E. M. Petriu, A. Albu 和 I.-C. Mituletu, “基于假肢肌电的控制系统结构和进化模糊模型”, Proc. 26th Mediter. 会议. Control Autom., 扎达尔, 克罗地亚, 2018 年, 第 625-630 页。
- [14] P. Wide, E. M. Petriu 和 M. Siegel, “用于康复和增强人类自然能力的感知和感知”, 载于 Proc. 2010 年 IEEE 机器人和传感器环境国际研讨会, 美国亚利桑那州凤凰城, 2010 年, 第 75-80 页。
- [15] S. Hochreiter 和 J. Schmidhuber, “长短期记忆”, 神经计算机, 卷. 9, 没有. 8, 第 1735-1780 页, 1997 年 11 月。
- [16] F. A. Gers, J. Schmidhuber 和 F. Cummins, “学会忘记: 使用 LSTM 进行持续预测”, 神经计算, 卷. 12, 没有. 10, 第 2451-2471 页, 2000 年 10 月。
- [17] H.-J. 刘和 K.-Y. Young, “使用经验模式分解和自适应神经模糊推理系统进行基于上肢 EMG 的机器人运动控制”, J. Intell. 机器人. 系统, 卷. 68, 没有. 3, 第 275-291 页, 2012 年 12 月。
- [18] M. Borghetti, E. Sardini 和 M. Serpelloni, “用于测量手指屈曲以用于康复目的的传感手套”, IEEE Trans. 仪器. 测量值, 卷. 62, 没有. 12, 第 3308-3314 页, 2013 年 12 月。
- [19] Z. Ma, P. Ben-Tzvi 和 J. Danoff, “带外骨骼机器人手套的手部康复学习系统”, IEEE Trans. 神经系统. 康复. 英语, 卷. 24, 没有. 12, 第 1323-1332 页, 2016 年 12 月。
- [20] F. G. Filip, “大型复杂系统的决策支持和控制”, Ann. 牧师控制, 第一卷. 32, 没有. 1, 第 61-70 页, 2008 年 4 月。
- [21] J. Vaščák, “通过迁移算法适应模糊认知地图”, Kybernetes, 卷. 41, 没有. 3-4, 第 429-443 页, 2012 年 3 月。
- [22] S. Blažič, I. Škrjanc 和 D. Matko, “进化控制系统的鲁棒模糊自适应法则”, Evolv. 系统, 卷. 5, 没有. 1, 第 3-10 页, 2014 年 3 月。
- [23] S. Formentin, P. De Filippi, M. Corno, M. Tanelli 和 S. M. Savaresi, “制动控制系统的数据驱动设计”, IEEE Trans. 控制系统技术, 卷. 21, 没有. 1, 第 186-193 页, 2013 年 1 月。
- [24] Z. C. Johanyák, “一种改进的粒子群优化算法, 用于优化串联式混合动力电动汽车中的模糊分类子系统”, Tech. Vjesnik——技术. 天然气, 卷. 24, 没有. 2, 第 295-301 页, 2017 年 6 月。
- [25] L. Fozo, R. Andoga, K. Beneda 和 J. Kolesár, “工作点选择对 iSTC-21v 和 TKT-1 小型涡轮增压器发动机非线性实验识别的影响”, 期间. 聚特. 反式. 英语, 卷. 45, 没有. 3, 第 141-147 页, 2017 年 10 月。
- [26] H.-X. Lang, M. T. Khan, K.-K. Tan 和 C. W. de Silva, “视觉伺服控制在自主移动救援机器人中的应用”, Int. J. 计算. 通信. 控制, 卷. 5, 第 685-696 页, 2016 年 10 月。
- [27] B. Kovács, G. Szayer, F. Tajti, M. Burdelis 和 P. Korondi, “一种通过适应动物运动属性进行移动机器人路径规划的新型势场方法”, 机器人. 奥顿. 系统, 卷. 82, 第 24-34 页, 2016 年 8 月。
- [28] E. Osaba, X.-S. Yang, F. Diaz, E. Onieva, A. Masegosa 和 A. Perallos, “一种离散萤火虫算法, 用于解决丰富的车辆路径问题, 为具有回收政策的报纸分发系统建模”, Soft Comput., 卷. 21, 没有. 18, 第 5295-5308 页, 2017 年 9 月。
- [29] M. Gánsari 和 C. Buiu, “异构机器人群的软件系统集成”, Control Eng. 申请信息, 卷. 19, 没有. 3, 第 49-57 页, 2017 年 9 月。
- [30] P. Angelov 和 R. Yager, “一种新型简化的基于模糊规则的系统”, Int. J. Gen. Syst., 第一卷. 41, 没有. 2, 第 163-185 页, 2012 年 2 月。
- [31] 关于. Precup, M. L. Tomescu, S. Preitl, E. M. Petriu, J. Fodor 和 C. Pozna, “一类 MIMO 模糊控制系统的稳定性分析和设计”, J. Intell. 模糊系统, 卷. 25, 没有. 1, 第 145-155 页, 2013 年 3 月。
- [32] 关于. Precup, R.-C. David 和 E. M. Petriu, “基于灰狼优化器算法的参数灵敏度降低的模糊控制系统调整”, IEEE Trans. 工业电子, 卷. 64, 没有. 1, 第 527-534 页, 2017 年 1 月。
- [33] S. Vrkalic, T.-A. Teban 和 I.-D. Borlea, “通过优化设计的稳定 Takagi-Sugeno 模糊控制”, Int. J. Artif. 情报, 卷. 15, 没有. 2, 第 17-29 页, 2017 年 10 月。
- [34] G. Navarro, D. K. Umberger 和 M. Manic, “VD-IT2, 使用 2 型模糊控制器在磁盘阵列上克隆虚拟磁盘”, IEEE Trans. 模糊系统, 卷. 25, 没有. 6, 第 1752-1764 页, 2017 年 12 月。
- [35] I. Dumitrache, N. Constantin 和 M. Drăgoicea, Retele neurale: identificarea si conducerea proceselor. 布加勒斯特: Matrix Rom, 1999。
- [36] A. Alique, R. E. Haber, R. H. Haber, S. Ros 和 C. Gonzalez, “基于神经网络的切削过程切削力预测模型. 一个真实案例的进展研究”, 在 Proc. 第 15 届 IEEE 国际症状. 智能. Control, 帕特雷, 希腊, 2000 年, 第 121-125 页。
- [37] M. Wagarachchi 和 A. Karunananda, “使用神经可塑性优化人工神经网络架构”, Int. J. Artif. 情报, 卷. 15, 没有. 1, 第 112-125 页, 2017 年 3 月。
- [38] J. Saadat, P. Moallem 和 H. Koofgar, “使用和声搜索算法训练回声状态神经网络”, Int. J. Artif. 情报, 卷. 15, 没有. 1, 第 163-179 页, 2017 年 3 月。
- [39] V. Fioriti 和 M. Chinnici, “网络中的节点资历排名”, 螺柱. 信息格式. 控制, 卷. 26, 没有. 4, 第 397-402 页, 2017 年 12 月。
- [40] C. M. Ionescu, “神经动力学阶梯模型中的相位恒定性”, IEEE Trans. 系统. 人类. 卷. 42, 没有. 6, 第 1543-1551 页, 2012 年 11 月。
- [41] C. M. Ionescu, D. Copot 和 R. De Keyser, “具有集中分数阶扩散室的呼吸阻抗模型”, IFAC Proc. 卷. 46, 没有. 1, 第 260-265 页, 2013 年 2 月。
- [42] D. Copot, R. De Keyser, E. Derom, M. Ortigueira 和 C. M. Ionescu, “减少肺功能评估的分数阶阻抗估计偏差”, Biomed. 信号处理. 控制, 卷. 39, 第 74-80 页, 2018 年 1 月。